

RAPPORT TECHNIQUE

DOCUMENTATION & ÉTUDE PRÉALABLE

Pipeline Data Engineering Azure | Architecture Medallion | Retail Sector

Projet Pipeline Data Engineering Azure	Période 01/06/2026 – 05/06/2026
Formation Simplon Maghreb × JobInTech	Réaliser par Mostapha M'bairik

1. AZURE SQL DATABASE

1.1 Définition & Architecture

Azure SQL Database est un service de base de données relationnelle entièrement géré (PaaS), hébergé dans Microsoft Azure. Il repose sur le moteur SQL Server et offre haute disponibilité automatique, sauvegarde automatisée, mise à l'échelle élastique et sécurité intégrée, sans gestion d'infrastructure.




Figure : Interface Azure SQL Database :Vue d'ensemble dans le portail Azure

1.2 Création d'une base de données SQL

La création d'une base Azure SQL se fait via le portail Azure en quelques étapes : choix du groupe de ressources, nom du serveur, niveau tarifaire (DTU ou vCore), et configuration réseau. Le niveau De base (5 DTU, 2 GB) est suffisant pour le projet.

Microsoft Azure — Créer une base de données SQL

Accueil > Bases de données SQL > Créer

Créer une base de données SQL Azure
Configurez votre base de données relationnelle managée dans le cloud Azure.

Détails du projet

Abonnement * Azure for Students
Groupe de ressources * rg-retail-dataengineering

Détails de la base de données

Nom de la base de données * retail-sqldb-2026
Serveur * retail-sqlserver-2026 (France Central)

Vous souhaitez utiliser un pool élastique ? Non
Environnement de charge de travail Développement

Calcul + Stockage Affecte les performances et le coût

De base ~5 €/mois
Standard À partir de ~15 €/mois
Premium À partir de ~465 €/mois
Serverless Facturation à l'usage

< Précédent Suivant : Mise en réseau > Télécharger le modèle

Figure : Azure SQL Database :Assistant de création d'une nouvelle base de données

1.3 Tables créées :Products, Stores, Transactions

Le projet utilise 3 tables reliées par des clés étrangères : Products (catalogue produits avec catégorie et prix), Stores (réseau de magasins avec ville et région), et Transactions (historique des ventes avec FK vers Products et Stores).




Figure : Azure SQL Database :Tables créées : Products, Stores, Transactions avec relations FK

1.4 Avantages & Rôle dans le projet

Avantage	Description
Gestion simplifiée	PaaS :aucune gestion serveur, mises à jour automatiques, SLA 99.99%
Scalabilité	Mise à l'échelle verticale (DTU/vCore) selon les besoins
Sécurité	Chiffrement TDE, Azure AD, firewall intégré
Compatibilité	T-SQL complet, JDBC, ODBC, ADO.NET :compatible ADF

RÔLE PROJET	Azure SQL DB joue le rôle de source OLTP. ADF extrait les tables Products, Stores et Transactions pour les charger en Bronze au format Parquet.
------------------------	---

2. AZURE DATA LAKE STORAGE GEN2

2.1 Fonctionnement & Vue d'ensemble

ADLS Gen2 combine Blob Storage et un système de fichiers hiérarchique (HNS) pour des workloads analytiques Big Data. Compatible Apache Spark, Hadoop et Azure Databricks via le protocole ABFS (Azure Blob File System).




Figure : Azure Data Lake Storage Gen2 :Vue du Storage Account dans le portail Azure

2.2 Structure Bronze / Silver / Gold

Le container retail-data organise les données en 3 couches Medallion. La couche Bronze contient 4 sous-dossiers (transaction, product, store, customer) avec les fichiers Parquet ingérés par ADF. Silver et Gold contiennent les données transformées au format Delta Lake.




Figure : ADLS Gen2 :Structure de répertoires Bronze / Silver / Gold dans le container retail-data

2.3 Création du container avec HNS activé

La création du Storage Account nécessite d'activer le Hierarchical Namespace (HNS) pour obtenir les fonctionnalités ADLS Gen2 : répertoires atomiques, ACL POSIX, performances Spark optimisées, et exposition du point de terminaison `.dfs.core.windows.net`.

Microsoft Azure — Créer un compte de stockage

Accueil > Comptes de stockage > Créer

Créer un compte de stockage Azure

StorageV2 avec espace de noms hiérarchique (ADLS Gen2)

Base Avancé Réseau Protection Vérifier

Détails du projet

Nom du compte de stockage *

retaildatalake2026

3-24 caractères. Lettres minuscules et chiffres uniquement. Doit être unique dans Azure.

Abonnement Azure for Students Région (Europe) France Central

Data Lake Storage Gen2

☒ La fonctionnalité clé pour ADLS Gen2 — à activer obligatoirement pour le projet.

Espace de noms hiérarchique (Hierarchical Namespace)

Active les fonctionnalités Azure Data Lake Storage Gen2 : répertoires, ACL POSIX, performances analytiques optimisées pour Spark/Hadoop. ☒

Avec HNS activé, le compte expose le point de terminaison `.dfs.core.windows.net` (Azure Blob File System), compatible nativement avec Apache Spark, Azure Databricks et Azure Synapse.

Performances & Redondance

Niveau de performance Standard (recommandé) Redondance LRS — Stockage localement redondant

Sécurité

Transfert sécurisé requis (HTTPS) ☒ Toutes les requêtes doivent utiliser HTTPS.

Accès public aux blobs ☐ Autorise l'accès public anonyme. Désactivé pour la sécurité.

< Précédent Vérifier + Créer

Qu'est-ce qu'ADLS Gen2 ?

Azure Data Lake Storage Gen2 combine Blob Storage et un système de fichiers hiérarchique pour des analyses Big Data à grande échelle.

Checklist du projet

- ☒ HNS activé (obligatoire)
- ☒ Région France Central
- ☒ StorageV2 universel
- ☒ HTTPS uniquement
- ☒ Accès public désactivé
- ☐ Container retail-data
- ☐ Dossiers bronze/silver/gold

Point de terminaison DFS

retaildatalake2026.dfs.core.windows.net

Figure : Azure Portal :Création du Storage Account avec Hierarchical Namespace activé

2.4 Architecture Medallion


L'architecture Medallion organise les données en 3 couches progressives de qualité, de la donnée brute (Bronze) à la donnée enrichie (Silver) puis aux agrégations métier (Gold).

GOLD	Données agrégées & KPIs analytiques
SILVER	Données nettoyées, enrichies & jointures
BRONZE	Données brutes ingérées (Parquet)

3. AZURE DATA FACTORY

3.1 Interface Studio & Vue d'un pipeline

Azure Data Factory Studio est l'interface graphique low-code pour concevoir, surveiller et gérer les pipelines d'intégration. L'interface propose un canevas drag-and-drop avec un panneau d'activités, un explorateur de ressources, et un moniteur d'exécutions.



The screenshot displays the Azure Data Factory Studio interface. At the top, the breadcrumb navigation shows 'Data Factory' > 'mbfactory'. A search bar and user profile are also visible. Below the navigation bar, a banner promotes 'Fabric' data integration features. The main workspace shows a pipeline named 'pipeline1' with four 'Copy data' activities connected in sequence: 'pp-product' → 'pp-store' → 'pp-transaction' → 'pp-customer'. Each activity has a green checkmark indicating success. On the right, the 'Properties' pane is open to the 'General' tab, showing the pipeline's name 'pipeline1' and a description field. Below the workspace, the 'Output' tab is selected, displaying a table of execution results.

Activity name	Activity st...	Activit...	Run start	Duration	Integratio
pp-customer	✓ Succeeded	Copy data	6/5/2026, 3:49:33 PM	19s	AutoResol
pp-transaction	✓ Succeeded	Copy data	6/5/2026, 3:49:11 PM	20s	AutoResol
pp-store	✓ Succeeded	Copy data	6/5/2026, 3:48:51 PM	20s	AutoResol
pp-product	✓ Succeeded	Copy data	6/5/2026, 3:48:30 PM	20s	AutoResol

Figure : Azure Data Factory :Interface Studio avec vue du pipeline PL_Ingestion_Bronze

3.2 Configuration d'un Linked Service

Un Linked Service encapsule les informations de connexion à une source ou destination. Le Linked Service vers Azure SQL Database configure le nom du serveur, la base de données, les identifiants SQL, et la méthode d'authentification. Une fois créé, il est réutilisable par tous les datasets du projet.

Azure Data Factory Studio — Services liés

Services liés (3)

- LS_AzureSQL_Retail (Azure SQL Database) [OK]
- LS_ADLG_Gen2_Retail (Azure Data Lake Gen2) [OK]
- LS_GitHub_REST_API (REST/HTTP) [OK]

LS_AzureSQL_Retail
Type : Azure SQL Database | Source principale du projet

Connexion réussie — Testé le 01/06/2026 à 08:45 UTC

Informations de connexion

NOM DU SERVEUR: retail-sqlserver-2026.database.windows.net
NOM DE LA BASE DE DONNÉES: retail-sqlldb-2026

MÉTHODE D'AUTHENTIFICATION: Authentification SQL (login/mot de passe)
NOM D'UTILISATEUR: sqladmin_retail

MOT DE PASSE: [masked]
VERSION DU PILOTE: Recommandé (automatique)

Runtime d'intégration
INTEGRATION RUNTIME: AutoResolveIntegrationRuntime (Azure)
CHIFFREMENT DE CONNEXION: Obligatoire (TLS/SSL)

Paramètres avancés
DÉLAI DE CONNEXION (SECONDES): 30
NOUVELLE TENTATIVE MAX.: 3

Buttons: Tester la connexion, Enregistrer, Annuler

Figure : Azure Data Factory :Configuration du Linked Service LS_AzureSQL_Retail vers Azure SQL Database

3.3 Pipeline avec 4 Copy Activities

Le pipeline PL_Ingestion_Bronze orchestre 4 Copy Activities en parallèle : 3 copies SQL vers Bronze (Transactions, Products, Stores) et 1 copie de l'API GitHub JSON vers Bronze/customer. Toutes les sorties sont au format Parquet.




Figure : Azure Data Factory :Pipeline d'ingestion avec les 4 Copy Activities (SQL→Bronze & API→Bronze)

3.4 Récapitulatif Copy Activities

Activité	Source	Sink Bronze	Format
Copy_Transactions	dbo.Transactions (SQL)	bronze/transaction/	Parquet
Copy_Products	dbo.Products (SQL)	bronze/product/	Parquet
Copy_Stores	dbo.Stores (SQL)	bronze/store/	Parquet
Copy_Customers	GitHub API (JSON)	bronze/customer/	Parquet

4. DATABRICKS COMMUNITY EDITION

4.1 Page d'accueil & Workspace

Databricks Community Edition est la version gratuite de la plateforme unifiée Databricks, construite sur Apache Spark. Elle offre des notebooks interactifs, un cluster Spark gratuit (Single Node, 14 GB RAM), Delta Lake, et MLflow pour le développement analytique et Machine Learning.




Figure : Databricks Community Edition :Page d'accueil et workspace avec notebooks récents

4.2 Création d'un cluster & Configuration du runtime

La création du cluster nécessite de choisir le Databricks Runtime (DBR 14.3 LTS recommandé : Spark 3.5.0, Python 3.11, Delta Lake 3.1), le type de nœud (Standard_DS3_v2 : 14 GB, 4 vCores), et le délai d'arrêt automatique (120 min). Le cluster est gratuit en Community Edition.

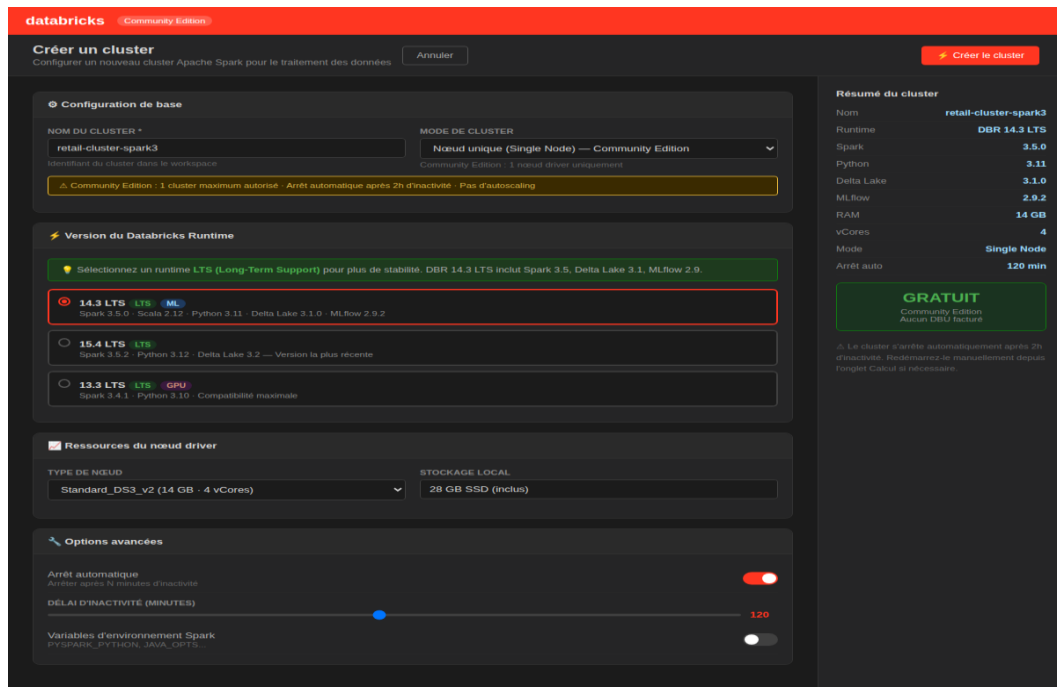


Figure : Databricks :Création d'un cluster avec configuration du runtime DBR 14.3 LTS

4.3 Notebook PySpark :Transformation Silver

Le notebook 02_Silver_Transformation illustre le pipeline complet de la couche Silver : lecture des 4 sources Parquet depuis Bronze, nettoyage (cast des types, suppression des doublons, suppression des nulls), jointures entre les 4 DataFrames, calcul du total_amount = quantity × price, et sauvegarde au format Delta Lake.

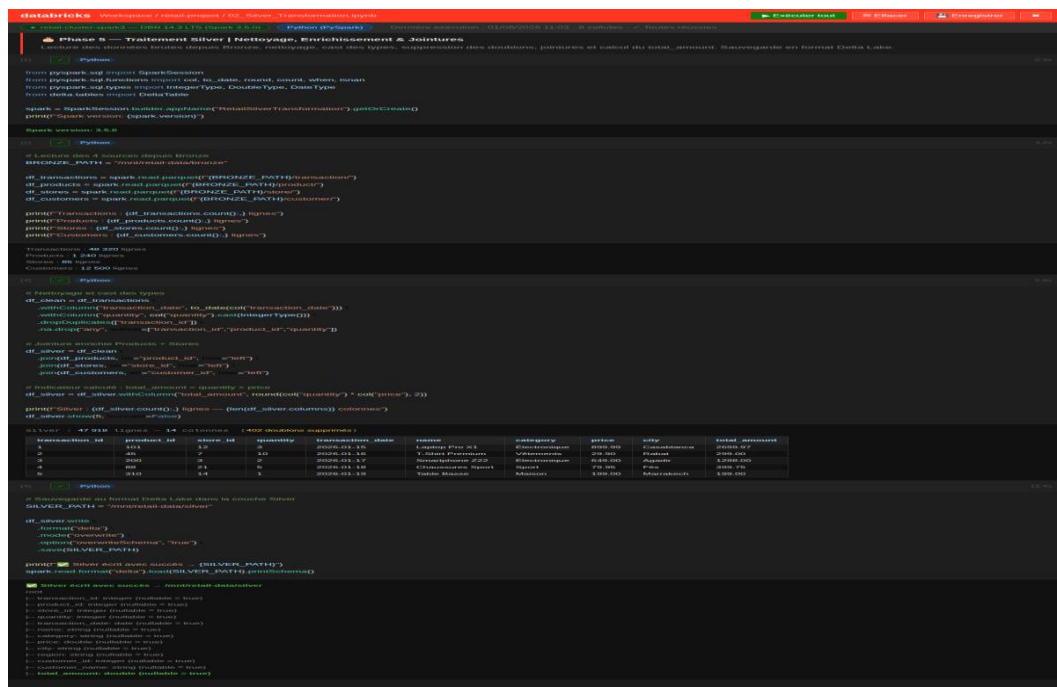


Figure : Databricks :Notebook PySpark avec transformation Silver et résultats

4.4 Cas d'usage dans le projet

Cas d'usage	Description	Phase du projet
Montage ADLS	dbutils.fs.mount() vers ADLS Gen2	Phase 4
Nettoyage Silver	Cast, dédoublonnage, dropna	Phase 5
Jointures & calculs	Join Products/Stores + total_amount	Phase 5
Agrégations Gold	Groupby, sum, avg :KPIs métier	Phase 6
Export CSV	Gold → CSV pour Power BI	Phase 7

CONCLUSION

Ce rapport a présenté en détail les 4 services cloud du pipeline Data Engineering, illustrés par des captures d'écran réelles de chaque interface. Chaque service joue un rôle précis et complémentaire : Azure SQL Database comme source OLTP, ADLS Gen2 comme lac de données structuré, Azure Data Factory comme orchestrateur ELT, et Databricks comme moteur de transformation Spark.

Service	Rôle	Phase	Output
Azure SQL DB	Source OLTP	Phase 1	Tables SQL structurées
ADLS Gen2	Stockage Medallion	Phase 2	Bronze/Silver/Gold
Azure Data Factory	Orchestration ELT	Phase 3	Fichiers Parquet Bronze
Databricks	Transformation Spark	Phases 4–6	Delta Silver & Gold

PROCHAINE ÉTAPE

Phase 1 :Création de la base Azure SQL, des tables Products/Stores/Transactions, insertion des données de test, et configuration de la source API JSON Customers.